

OPC-UAとディープラーニングによる工業生産製品の異常検知

Henry O. Velesaca^{1,2}, Dome'nica Carrasco¹, Dario Carpio¹, Juan A. Holgado-Terriza², Jose M. Gutierrez-Guerrero³, Tonny Toscano¹, Angel D. Sappa^{1,4}

¹ESPOL Polytechnic University, Escuela Superior Politécnica del Litoral, ESPOL, Campus Gustavo Galindo Km.30.5 Vía Perimetral, P.O. Box 09-01-5863, Guayaquil, Ecuador

²グラナダ大学ソフトウェア工学部、18014、グラナダ、スペイン

³Abbott Laboratories, 18004, Granada, Spain

⁴スペイン、バルセロナ、08193-ベラテラ、コンピュータビジョンセンター

キーワード 異常検知、インダストリー4.0、ディープラーニング、OPC-UA、YOLO v8。

要旨: 工業生産の領域では、製品の欠陥を検出することが、品質を維持するために不可欠である。人による検査に頼った従来の方法では、エラーが発生しやすく、時間がかかることが多い。しかし、オートメーションとコンピュータビジョンの進歩により、よりスマートな産業用制御システムが開発されている。本稿では、OPC-UAとYOLO v8を統合することで、産業プロセスの欠陥を特定する新しいアプローチを探索する。OPC-UAはセキュアな通信規格を提供し、機器間のシームレスなデータ交換を可能にする一方、YOLO v8は正確な物体検出を提供する。これらの技術を組み合わせることで、メーカーは生産ラインをほぼリアルタイムで監視し、不具合を迅速に分析し、是正措置を講じることができます。その結果、製品の品質と作業効率が向上する。ブリキの蓋の欠陥検出に関するケーススタディは、提案されたアプローチの有効性を実証している。PLC統合、画像アキュイジション、YOLO v8実装を含むシステム・アーキテクチャの詳細と、OPC-UAサーバーとYOLO v8モデル統合の性能評価について述べる。その結果、ラウンド・トリップ・タイムとEnd-to-End遅延の少ない効率的な通信が示され、欠陥検出におけるこのアプローチの可能性が強調された。コードはGitHub: <https://github.com/hvelesaca/OPC-UA-YOLOv8-Lid-Anomaly-Detection>。

1 はじめに

競争の激しい工業生産において、製品の欠陥をタイムリーに検出し修正することは、高水準の品質と業務効率を維持するために不可欠である（例えば、（Huang et al. 従来、このプロセスは人手による検査に大きく依存しており、この検査はエラーが発生しやすく、スピードと精度の点で限界があった（Montgomery, 2019）。しかし、自動化技術とコンピュータ・ビジョンの進歩により、よりスマートで効果的な産業用制御システムの実装が可能になった（（Verkhivker et al., 2020), (Dey and Agrawal, 2016)）。

近年、産業用通信プロトコルの進歩により、

スマート工場における品質評価の方法が変化している。これらのプロトコルは、スムーズなデータ交換と通信を可能にする。

センサー、機械、品質管理システムなど、製造プロセスのさまざまな要素間の通信を可能にする（Zheng et al.）これらのプロトコルを活用することで、メーカーは生産プロセスをリアルタイムで監視し、潜在的な欠陥や異常を分析し、製品の品質と規制基準を維持するための是正措置を迅速に実施することができる（Li et al.）

本稿では、工業試験場での製造における欠陥

を特定するための革新的な方法論に焦点を当て、2つの重要な技術を活用する： OPC-UA (Foundation, 2023) (Open Platform Communications Unified Architecture) と YOLO v8 (Jocher et al., 2023) (You Only Look Once version 8) です。OPC-UAは、産業環境における異なる機器やシステム間の相互運用性を促進する、堅牢で安全な通信規格を提供する。一方、YOLO v8は、コンピュータの分野で最先端の物体検出モデルである。

画像や映像中の物体を識別する速度と精度で知られるビジョン。

その中で、OPC-UAとYOLO v8を産業用制御システムに統合することで、欠陥をリアルタイムで検出・分類する能力を大幅に向上させ、製造プロセスにおけるあらゆる異常に対して、より迅速かつ効率的な対応を可能にする方法を探ります。さらにこの研究では、この手法の利点と潜在的な限界を示すケーススタディと実用的なアプリケーションを検証し、この手法の発展と産業界への普及に向けた将来的な可能性も検討する。

この作業を詳細に扱うため、原稿は以下のように構成されている。セクション2では、OPC-UAの使用、画像識別、および産業プロセス内での深層学習技術の使用に関するいくつかの関連研究を紹介する。セクション3では、OPC-UAとディープラーニング技術の統合を実施するための提案アプローチを示す。そして第4節では、ブリキの蓋の異常検出をケーススタディとした実験結果を示す。最後に、セクション5で結論を示す。

2 背景

前述したように、本稿ではOPC-UAとディープラーニング技術をキーエレメントとした産業用制御システムの統合を示すアプローチを紹介する。本セクションでは、本研究のトピックに関連する最も関連性の高い技術をいくつか要約する。

2.1 OPC-UAの概要

OPC-UA（Open Platform Communications Unified Architecture）は、異なる機器、システム、ソフトウェアプラットフォーム間の相互運用性を促進するために、産業環境で広く使用されている通信規格です。最新の産業環境における接続性の課題に

対処するために設計されたOPC-UAは、ほぼリアルタイムのデータ交換と異種システムの統合のための堅牢で安全なプラットフォームを提供します。

しかし、OPC-UAは通信プロトコルであるだけでなく、他のタスクの可能にしています。例えば、OPC-UA標準の中でも特に産業試験環境におけるアラームとコンディション管理に特化した、アラームの仕様（OPC-UA Part 9: Alarms and Conditions）を提供しています。この規格は、オートメーションと制御システムにおけるアラームとコンディションのモデリング、トリガー、管理、モニタリングのためのガイドラインを規定しています。また、パート（OPC-UA Part 11:

ヒストリカル・アクセス) は、OPC-UAサーバーに保存されたヒストリカルデータへのアクセスと検索に重点を置いています。これにより、クライアント・アプリケーションは、産業環境における分析、レポート、トレンド分析、その他のアプリケーションのためにヒストリカル・イン・フォーメーションを使用することができます。

(Georgi Martinov, 2017) により発表された研究は、異なる運動学を持つ機器を監視するためのOPC-UAプロトコルの使用を実証している。モーター位置、リニアエンコーダの読み取り値、および電気自動装置信号を含む、CNCシステムからのデータ取得に焦点を当てています。この実装では、OPCサーバー用の別個のアダプターは必要ありません。さらに、OPC-UAは「Publisher-Subscriber」モデルを通じてクライアント側のデータ検索を効率化し、運動学スキーマの変更を可能にします。しかし、ネットワーク接続の問題や、信頼性の低いネットワーク環境におけるOPC-UAサーバーの可用性といった課題が生じる可能性があります。

さらに、(Nedeljkovic and Jakovljevic, 2020) は、Omron CPIL-EM40DT-D PLC によって制御される「ピックアンドプレイス」システムを使用した製造サイクルの問題を取り上げた。この問題は、部品が正しく位置決めされないまま頻繁にシステムに入ることから生じた。これを解決するために、OPC-UA標準を使用してビジョンセンサとハンドリングシステム間の通信を確立しました。これにより、部品の向きに関する情報が送信され、マニピュレーターがカメラからのデータを受信できるようになると、センサーに信号が送られるようになりました。OPC-UAを導入することで、スマートビジョンセンサーの交換が、配線の作り直しや変更なしに簡単に行えるという利点がありました。しかし、以前のOPC DAサーバーからの移

行には複雑な問題があり、OPC-UA規格に機能を適合させるためにOPC Expertを使用することになりました。

一方、(Schafer)が発表した論文では (et al., 2022) は、強化学習 (RL) を産業環境に統合してオペレーションを最適化し、意思決定を強化するためのアーキテクチャを概説しており、シームレスでセキュアなデータ交換のためのOPC-UAの利用に重点を置いている。このフレームワークには、OPC-UAを介したセンサーやIoTデバイスからのリアルタイムのデータ収集、このデータの前処理、環境との継続的な相互作用を通じて最適な戦略を学習するRLモデルの学習が含まれます。学習されたモデルは、産業制御システム内に配置され、リアルタイムの意思決定を行う。このシステムには、モデルを継続的に改善し再学習させるためのモニタリングとフィードバックのメカニズムも組み込まれており、様々な産業適応性とスケーラビリティを確保し最終的にはよりインテリジェントで自律的なプロセスを実現します。

最後に、オブジェクト指向の原則に基づき、Gutierrez ら (Gutierrez-Guerrero and Holgado-Terriza, 2017) は、産業オートメーションシステムを概念化するためのメタモデルiMMASを提案している。このメタモデルには、製造制御システムの開発とデプロイメントを簡素化する具体的な構文と特定のセマンティクスが含まれている。これらの、モデルをPLCプログラムやOPC-UAデータモデルに変換することができる。

2.2 物体認識

産業環境における物体認識は、幅広い産業用途において効率、品質、安全性を向上させる強力なツールとして浮上している。コンピュータビジョン技術とディープラーニングの進歩により、企業は作業環境を視覚的に分析・理解する機械の能力をますます活用するようになっている。一方、産業環境における物体認識では、機械学習アルゴリズムとモデルを使用して、カメラやビジョンデバイスで撮影された画像内の特定の物体、パターン、または特徴を認識します。これらのシステムは、製品の欠陥検出、機器の性能監視、品質検査などを行うことができる。

例えば、(Dominguez et al., 2006)の論文は、厳しい産業環境における物体の認識と検査の複雑さを扱っている。彼らは高度なコンピュータビジョン技術、特にYOLO v8畳み込みニューラルネットワークを使用して、リアルタイムでの物体検出とクラス分類を強化している。YOLO v8の能力は、悪条件下でも高速かつ正確な検出を可能にし、工業検査プロセスを改善する。しかし、多様な学習データセットの必要性、様々な環境条件への適応、計算機資源の必要性などの課題が、実装の成功を妨げる可能性がある。従来から、実用的な工業試験環境において最適な結果を得るためには、パ

ラメータの微調整に関する専門知識が不可欠です。

一方、(Rocha et al., 2014) は、産業用セットにおける物体認識と姿勢推定のために設計されたカスケード・システムを紹介している。このシステムは、YOLOのようなディープラーニング技術を用いた物体検出から始まり、物体の向きを決定するための姿勢推定アルゴリズムに続く、いくつかの段階から構成される。これらの手法を統合することで、本システムは物体のポーズを特定し、正確に推定する際に強固な性能を発揮し、産業における自動化と品質管理プロセスを強化する。しかしながら、オクルージョン、照明の変化、および

複雑な背景は、物体認識と姿勢推定の精度と信頼性に影響を与える可能性がある。さらに、カスケードシステムの計算の複雑さは、産業環境でのリアルタイム展開のための効率的なハードウェアリソースを必要とする可能性がある。

2.3 産業システムにおけるディープラーニング

人工知能、特にディープラーニング（深層学習）分野の進歩は、産業システムの最適化と自動化に新たなフロンティアを開いた。その中で、大量のデータを処理し、複雑なパターンを識別し、業務効率を向上させるディープラーニングの能力は、産業システムにおけるディープラーニング技術の利用をますます重要視している。この記事では、産業環境におけるディープ・ニューラル・ネットワークの影響と応用を探求し、品質向上、故障予測、プロセス最適化、生産コスト削減の可能性を強調する。

著者らは、産業環境における故障診断のための様々なディープラーニング技術を提案し、ユニークなパターンを識別し、正確でタイムリーな検出を保証する能力を強調している。課題はモデル結果の解釈と既存の監視システムとの統合である。例えば、(Surendran et al., 2022)が発表した研究は、早期故障検出のための大規模データセットの分析における深層学習の有効性を強調しているが、学習データの要求が高く、計算が複雑であることを指摘している。一方、(Iqbal et al., 2019)が発表した論文では、故障検出と分離に取り組んでおり、複雑なパターンを検出する深層学習モデルの能力を明らかにしているが、広範なデータと多大な計算再ソースが必要であることも認識している。(Sa´nchez Santalices et al., 2023)が発表した研究は、トレイ異常検出のためのニューラルネットワ

ーク実装を実証しており、早期問題検出のための不規則なパターンを識別することができる。しかしながら、代表的な訓練データが必要であり、偽陽性または偽陰性の可能性があるため、モデルの最適化とチューニングを注意深く行う必要がある。

3 提案アプローチ

本節では、提案する各ステージについて詳述する。図1に、提案アプローチのシステムアーキテクチャを示す。システムアーキテクチャーは、3つのレイヤーを持つ階層産業システムに基づいている。

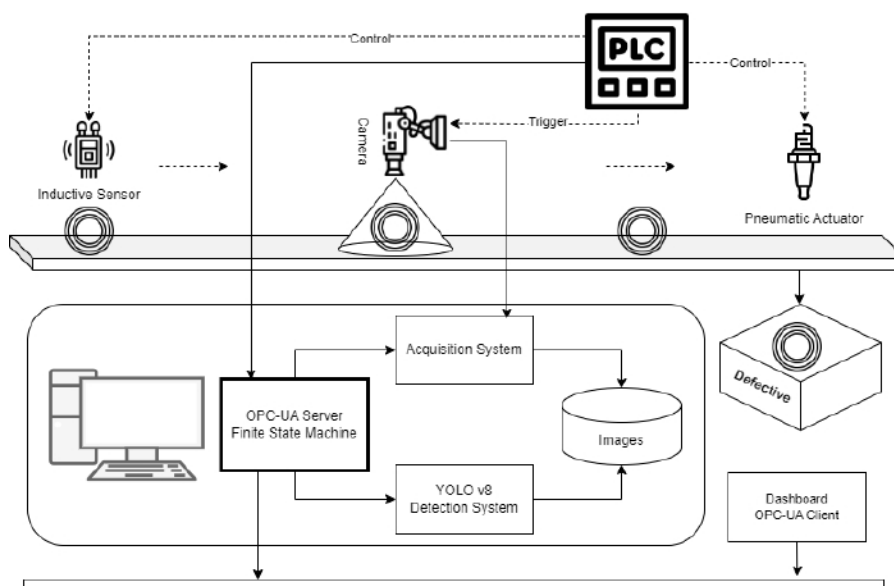


図1: 本稿で提案するシステム・アーキテクチャの概要。

メインOPC-UAサブシステムが、プラント状態の検索、カメラからの画像取得、およびディープ・ニューラル・ネットワークに基づく異常検出の適用を担当する監視層、そして最後に、c) オペレーターがダッシュボードを使用してプラントの進化を調べることができる可視化層。

3.1 システム概要

提案の評価は、ブリキの蓋の故障検出システムのケーススタディに基づいている。本研究で提案するアーキテクチャでは、ベルトコンベア、PLC、誘導センサーが蓋の通過を検出するために使用される。さらに、産業用カメラと照明システムで構成されるビジョンシステムが使用される。さらに、カメラはワークステーションに接続されており、OPC-UAサーバーとディープニューラルネットワークの実行も可能である。

3.2 OPC-UAサーバー

我々の提案では、OPC-UAサーバーを工業プロセスの欠陥検出システムに統合することで、ほぼリ

アルタイムのデータ収集に統一された安全なインターフェースを提供し、重要な役割を果たします。OPC-UAの相互運用性とセキュリティ機能を活用することで、プラントフロアの異なるデバイスやシステムから収集されたデータの整合性と信頼性を確保することができます。この統合により、継続的かつ効率的なプロセス監視が可能になり、欠陥検出のための強固な基盤を提供します。

3.3 YOLO v8

検出サブシステムの画像識別コンポーネントで使われるニューラルネットワークは、YOLO v8 (Jocher et al., 2023)である。これは、画像内の物体を検出する際の効率と速度のために選択されたもので、高速応答が要求される産業環境でのリアルタイム・アプリケーションに適している。さらに、1回のパスで複数のオブジェクトを識別できるため、複数の凹凸がある工業製品の欠陥を識別するのに理想的である。また、YOLO v8は、異なる照明条件、視野角、欠陥の種類に適応するための調整と最適化が簡単にできる、深く柔軟なアーキテクチャを提供しています。このため、産業環境における複雑で多様な欠陥検出の課題に対処するための有効な選択肢となる。最後に、YOLO v8はオープンソースであり、その広範な開発者コミュニティにより、YOLO v8ベースの欠陥検出システムの実装と長期保守が容易になっている。

3.4 OPC-UAサーバーとYOLO v8の統合

OPC-UAサーバーとYOLO v8のような高度な欠陥検出アルゴリズムを組み合わせることで、ほぼリアルタイムで欠陥を識別・分類するシステムの能力を大幅に向上させることができます。OPC-UAサーバーから提供される正確でタイムリーなデータを使用することで、欠陥検出アルゴリズムは効果的にトレーニングされ、幅広い種類の欠陥を高い精度で認識できるように調整されます。これらの技術を統合することで

産業プロセスの品質と効率を向上させる包括的かつ効果的なアプローチ。このアプローチは、ダウンタイムと生産コストを同時に削減します。

3.5 評価指標

提案作品の評価では、RTT (Round Trip Time) と End-to-Endの遅延メトリクスを計算し、サーバーのパフォーマンスを確立する。RTTとは、データパケットが送信元から宛先まで移動し、その後送信元に戻るまでにかかる時間を示す指標である。

E2Eとはネットワーク化されたシステムにおいて、情報が送信元から宛先まで移動するのにかかる時間のことです。これらの測定基準は、オンライン・アプリケーションやサービスの通信速度や応答性に直接影響するため、ネットワークのパフォーマンスを評価する上で重要です。どちらの測定基準も、コンピュータ・ネットワークでは一般的に、待ち時間やネットワークの応答時間を評価するために使用される (Eckhardt and Müller, 2019)。

° SCIENCE AND TECHNOLOGY PUBLICATIONS

4 ケーススタディ

本セクションでは、提案フレームワークで得られたケーススタディの実験結果を示す。提案手法の性能評価には、RTTとE2E測定を使用した。

4.1 システム導入

図1に示すシステムアーキテクチャを考慮して、内のブリキ蓋の製造欠陥を検出するシステムの実装を示す。主要要素として、制御層には Siemens S7 1200 PLC が使用されている。さらに、産業用可視スペクトルカメラで構成されるビジョンシステムが照明システムとともに使用されている。このシステムには、コンベアベルト上の蓋を検出す

るために使用される誘導センサーもある。スーパービジョン層には、インテル・コアI9を搭載したワークステーションが使用されている。

3.3GHzのCPUとNVIDIA Titan XP GPUを搭載し、YOLO v8による画像識別のトレーニングとテストを行う。OPC-UAは、画像の取得とOPC-UAサーバーおよびYOLO v8の実行を担当します。図2は、システム・アーキテクチャで使用されている主なコンポーネントを示しています。

4.2 画像取得

第一段階として、状態の良いブリキ蓋と欠陥のあるブリキ蓋の画像の取得が確立されている。最も一般的な欠陥は、傷、へこみ、そして



図 2: (左上) Siemens S7 1200 PLC。(左下) HMI TP700 comfort。(右上) ビジョンシステムと照明システム。(右下) 誘導センサー。

表1: データ取得の分布。

タスク	グッド	不良品
トレーニング	457	588
バリデーション	85	112
テスト	29	36
合計	571	736

インサイドエッジのラバー不足。表1は、YOLO v8が後段で使用するトレーニング、検証、テスト段階に使用したデータの分布を示す。

4.3 OPC-UAサーバーの実装

次のステップはOPC-UAサーバーの実装であり、OPC-UAのパート16で規定されている有限状態マシン（FSM）の設計が定義されています（図3を参照）。また、OPC-UAサーバーを作成するために、FSMに基づき、(Ve-lesaca et al., 2024)によって提案された方法論を使用して動作モデルを定義しました。図4で作成したモデルから、Free OPC-UA Modeler（FreeOpcUa, 2 28）を使用して、OPC-UAサーバーをXML形式で作成します。

XML形式のモデルを取得したら、次はサーバーのデプロイです。使用言語はPythonなので、OPC-UAサーバーのデプロイを実行するために、2つのファイルが作成されます：*Server.py*と*Utils.py*です。*Server.py*ファイルにはサーバーの一般的な構造とOPC-UAプログラムを表現するクラスが定義されており、具体的にはFSMの動作を含むメソッドが実装されています、

表2: 有限状態マシン遷移。

いいえ	名前の変遷	原因	オリジン州	目的地の州	効果
1	ハルテッド・トゥ・レディ	リセット方法	停止	準備完了	レポート トランジション1 イベント/結果
2	レディートゥランニング	開始方法	準備完了	ランニング	レポート トランジション2 イベント/結果
3	RunningToHalted	停止方法または内部（エラー）	ランニング	停止	レポート トランジション3 イベント/結果
4	RunningToReady	内部	ランニング	準備完了	レポート トランジション4 イベント/結果
5	ランニング・トゥ・サスペンデッド	サスペンド方式	ランニング	中断	レポート トランジション5 イベント/結果
6	サスペンデッド・トゥ・ランニング	履歴書の書き方	中断	ランニング	レポート トランジション6 イベント/結果
7	サスペンデッド・トハルテッド	停止メソッド	中断	停止	レポート トランジション7 イベント/結果
8	サスペンデッド・トゥ・レディ	内部	中断	準備完了	レポート トランジション8 イベント/結果
9	レディトハルテッド	停止メソッド	準備完了	停止	レポート トランジション9 イベント/結果
10	検出から検出へ	内部	検出	検出	レポート トランジション10 イベント/結果
11	検出から取得へ	内部	検出	買収	レポート トランジション11 イベント/結果
12	獲得から獲得へ	内部	買収	買収	レポート トランジション12 イベント/結果
13	取得から分類まで	内部	買収	分類	レポート トランジション13 イベント/結果
14	分類から分類へ	内部	分類	分類	レポート トランジション14 イベント/結果
15	分類から検出へ	内部	分類	検出	レポート トランジション15 イベント/結果

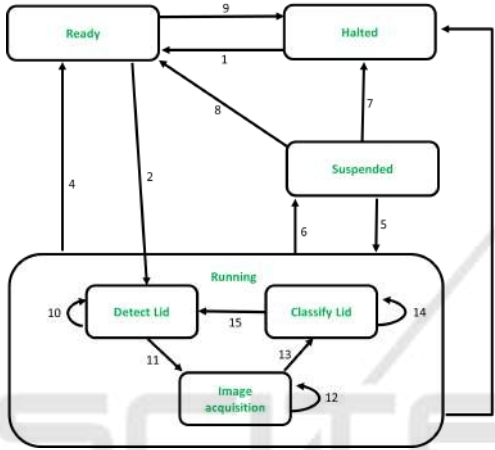


図3: ブリキ蓋の欠陥検出システムの有限状態マシン。

また、OPC-UA が提供するセマンティクスを使用して、表 2 に定義された状態間の遷移を評価します。*Utils.py* ファイルにはサーバー作成用の追加関数が含まれています。最後のステップはサーバーの実行です。

4.4 YOLO v8の実装

学習フェーズを開始する前の最初のステップとしてAlbumentationsライブラリを使用して学習用の例数を増やすことにした。このライブラリはデータの拡張を可能にし、YOLO v8のような物体検出モ

デルのトレーニングのようなコンピュータビジョ
ンタスクで一般的に使用されています。Albumentationsは、切り抜き、回転、明るさ、コントラスト
の変更など、幅広い画像変換を提供します。これ
らの変換は、学習データの前処理中にランダムか
つ制御された方法で適用することができ、現実的
なバリエーションを持つオリジナル画像のインス
タンスを生成します。

図5は、分類タスクのYOLO v8による単独モー
ドでの実行コードである。

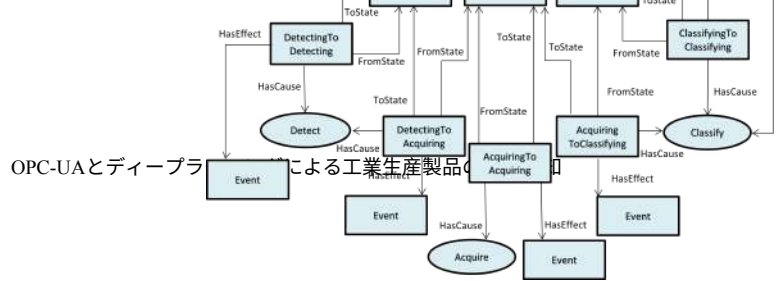


図4： OPC-UA表記による行動モデル（Velesaca et al, 2024）。


```
yolo classify train data="dataset/" \
model=yolov8m-cls.pt epochs=500 imgsz=640
```

図5： YOLO v8でトレーニングデータに対して実行されたコード。

実行パラメータとして、モデル *"yolov8m-cls.pt "* と500トレーニングエポックを用いる。学習／検証タスクを完了した結果、図6に示す正規化コンフュージョン行列が得られる。さらに、93%の精度が得られた。

テストタスクには、図8に示すコードをする。さらに、定性的および定量的な

図6： YOLO v8を用いて学習したネットワークの正規化混同行列。






図7: YOLO v8の予測結果。これらの画像はテストセットの一部である。

```
$yolo classify predict source="test/" \
model="train/weights/best.pt"
```

図8: YOLO v8でテストデータに実行されたコード。

```
def run(self):
    while (真):
        if self.sCurId.getvalue()==self.sRun.nodeid:
            if self.sCurId.getvalue()==self.sDet.nodeid:self
                .Detecting()
            elif self.sCurId.getvalue()==self.sAcq.nodeid:self
                .Acquirig()

            # 画像1枚にコメント
            results=model(imageto predict)
            # インデックス: defective(0), good(1)
            pred=results[0].probs.cpu().detach().numpy()
            if(pred[0]>pred[1]):d
                efective=True
                ア・コーチ・ヴァルテ・ア・コーチ・トゥ・ア・ラー()
                print("Defective")
            って:
                defective=False
                print("Good")

        elif self.sCurId.getvalue()==self.sClas.nodeid:
            self.を()
```

(邦題)

た変数の1つはトリガー信号で、誘導センサーの読み取り値をキャプチャし、カメラからの距離に基づいてキャプチャを実行する必要があるかどうかを判断する。画像が読み取られると、YOLO v8予測システムに送られます。

⁽¹⁾<https://pypi.org/project/python-snap7/>

図9: YOLO v8でOPC-UAサーバーのFSMで実行されるコード。

テスト用サブセットでの評価を図7に示す。

4.5 OPC-UAサーバーとYOLO v8の統合

PLC と OPC-UA サーバ間の通信を確立するには、Snap7¹ ライブラリを使用します。PLCに設定され

表3: End-to-End遅延とラウンド・トリップ・タイムの性能評価（ミリ秒単位）。
エラーが発生しやすく

画像サイズ		ペイロード (kB)	E2E (ミリ秒)	通信事業者 (ミリ秒)
幅	高さ			
1440	1080	1555200	237	275
1080	810	1166275	209	231
720	540	777450	178	189
360	270	388690	159	168

ブリキの蓋が不良品か良品かを判断できるようにする。不良品であれば空気圧アクチュエーターが作動して破損品を分離する。

YOLO v8で学習されたモデルの実行はOPC-UAサーバーのスコープ内で行われ、さらに、有限状態機械モデルを用いて状態変化が実行される。図9は、YOLO v8で学習されたモデルの実行が行われるOPC-UAサーバーのコードを示している。

4.6 評価指標

最終段階として、OPC-UAサーバーとYOLO v8の性能をほぼリアルタイムで評価するために、2つのメトリクスを使用します。エンドツーエンド遅延（E2E）とラウンドトリップタイム（RTT）です。E2Eは、パケットが送信元から宛先までネットワークを介して伝送されるのにかかる時間を指します。IPネットワーク・モニタリングでは一般的な用語であり、ソースから宛先までの一方向のパスのみが測定される点で、RTTとは異なる。さらに、この測定値の計算には100枚の画像が考慮される。

5 結論

本稿では、OPC-UAとYOLO v8を連携させることで、工業プロセスにおける異常検知を改善する方法を提案する。従来の人手による検査方法は、工

そのため、より自動化された正確なソリューションの必要性が強調されている。この記事では、PLC、産業用カメラ、OPC-UAサーバー、YOLOv8モデルなどのコンポーネントを含む、提案システムのアーキテクチャについて詳しく説明する。効率的なほぼリアルタイムの欠陥検出を実現するために、これらのコンポーネント間の相互作用が強調されている。さらに、システムの効率を評価するためのRTTやE2Eなどの性能指標を含む実験結果を。

最後に、産業環境においてOPC-UAとYOLOv8を組み合わせて使用することで、セキュアで標準化された通信、機器間の相互運用性ほぼリアルタイムのモニタリングなど、大きな利点が得られます。OPC-UAはシームレスで保護されたデータ交換を可能にし、YOLOv8は高速で正確なオブジェクト分類を提供することで、目視検査を自動化し、人的ミスを減らします。さらに、OPC-UAの履歴データへのアクセスと分析機能は、予知保全とプロセスの最適化を促進し、運用効率と製品品質を向上させます。

謝辞

本研究の一部は、ESPOLプロジェクト "Automatización del proceso de tención de fallas en piezas de hojalata usando visión por computador" (CIDIS-004-2023) およびグラナダ大学の支援を受けている。

参考文献

- Dey, S. and Agrawal, M. K. (2016).持続可能な包装材料としてのブリキ: Recent innovation and developments to remain environment friendly and cost effective. *Int. J. Res. IT Manag. Eng.*, 8:9-22.
- Dominguez, E., Spinola, C., Luque, R. M., Palomo, E. J., and Munoz, J. (2006).困難な産業環境における物体認識

と検査。In *Int. Conf. on Industrial Technology*, pages 989-993. IEEE.

Eckhardt, A. and Müller, S. (2019).opc uaとtsnベースのピアツーピア通信の往復時間の分析。In *Int. Conf. on Emerging Technologies and Factory Automation (ETFA)*, pages 161-167. IEEE.

Foundation, O. (2023).OPC統一アーキテクチャ。取得済み：2023年12月。

FreeOpcUa (最終アクセス: 2024-02-28).FreeOpcUa Modeler. <https://github.com/FreeOpcUa/opcuamodeler>.

Georgi Martinov, Roman Pushkov, S. E. (2017).Opc ua- based smart manufacturing : System architecture, implementation, and execution. *IEEE*.

Gutierrez-Guerrero, J. M. and Holgado-Terriza, J. A. (2017). iMMAS an Industrial Meta-Model for Au-

- OPC UA を用いたトメーションシステム
Elektronika Ir Elek- trotechnika, 23((3)):3-11.
- Huang, H.-W., Wu, S.-J., Lu, J.-K., Shyu, Y.-T., and Wang, C.-Y. (2017). 食品産業における高圧処理の現状と今後の動向. *Food Control*, 72:1-8.
- Iqbal, R., Maniak, T., Doctor, F., and Karyotis, C. (2019). ディープラーニングアプローチを用いた工業プロセスにおける故障検出と隔離. *Transactions on Industrial Informatics*, 15(5):3077-3084.
- Jocher, G., Chaurasia, A., and Qiu, J. (2023). Ultralytics yolov8.
- Li, Q., Tang, Q., Chan, I., Wei, H., Pu, Y., Jiang, H., Li, J., and Zhou, J. (2018). Smart manufacturing standardization: アーキテクチャ、参照モデル、標準フレームワーク. *Computers in Industry*, 101:91-106.
- Monteiro, C. A., Cannon, G., Lawrence, M., Costa Louzada, M. d., and Pereira Machado, P. (2019). 新星分類システムを用いた超加工食品、食事の質、および健康。 *ローマ: FAO*, 48.
- Montgomery, D. C. (2019). *Introduction to statistical quality control*. John Wiley & sons.
- Nedeljkovic, D. M. and Jakovljevic, Z. B. (2020). opc-uaを用いたマニピュレータ制御システムへのスマートビジョンセンサの統合. *IEEE*.
- Rocha, L. F., Ferreira, M., Santos, V., and Moreira, A. P. (2014). 産業アプリケーションのための物体認識と姿勢推定: カスケードシステム. *Robotics and Computer-Integrated Manufacturing*, 30(6):605- 621.
- Sa´nchez Santalices, J., Moya de la Torre, E. J., and Poncela Me´ndez, A. V. (2023). (2023). バンジージャンプにおける異常検出のためのニューロンレッドの実装。 *Jornadas de Automa´tica*, pages 873-878. Universidade da Coruˆna. Servizo de Publicacio´ns.
- Scha´fer, G., Kozlica, R., Wegenkittl, S., and Huber, S. (2022). 強化学習を産業導入するためのアーキテクチャ. In *Int. コンピュータ支援システム理論会議*, pages 569-576. Springer.
- Surendran, R., Khalaf, O. I., and Tavera Romero, C. A. (2022). Deep Learning based intelligent industrial fault diagnosis model. *Computers, Materials & Continua*, 70(3).
- Velesaca, H. O., Holgado-Terriza, J. A., and Gutierrez-グティエレス, J. M. (2024). スマート工場運営の最適化: OPC-UAに基づく産業システム実装への方法的アプローチ. In *Int. Int. Conf. of Applied Industrial Engineering*, pages 1-15.
- Verkhivker, Y., Altman, E. I., Dotsenko, N. V., and Miroshnishenko, E. (2020). 食品容器を製造する際の材料に対するコモディティ・アプローチ. *Iuniper Online Journal Material Science*, 6(3):555687.
- Zheng, P., Wang, H., Sang, Z., Zhong, R. Y., Liu, Y, C., Mubarak, K., Yu, S., and Xu, X. (2018). インダストリー4.0のためのスマート製造システム: 概念的枠組み、シナリオ、将来の展望. *Frontiers of Mechanical Engineering*, 13:137-150.